

Tecnicatura:

TECNICATURA SUPERIOR EN CIENCIA DE DATOS E INTELIGENCIA ARTIFICIAL



| 2do Cuatrimestre
| **MÓDULO**

ESTADÍSTICA & EXPLORACIÓN DE DATOS II - CIENCIA DE DATOS II

| Docentes: Marcos Ugarte - Nahuel Pratta

| Grupo: Unidad de Investigación & DataStay

Integrantes del Grupo:

- Andrea P. Testa
- Valeria N. Villalba
- Mónica Dominguez
- Carlos García
- Raúl Moreno

1. NOMBRE | TÍTULO Unidad de Investigación & DataStay

2. TIPO: PROYECTO PREDICTIVO, PRESCRIPTIVO, EXPLORATORIO Y DE IMPLEMENTACIÓN de VENTAS y CATEGORÍA EN HOTELES.-

3. EJES | UNIDADES CONCEPTUALES:

Ejes Analíticos (Metodología Estadística):

- Regresión lineal.
- Regresión logística.
- Análisis de varianza (ANOVA): El reto hotelero. Unidades Conceptuales (Estructura del Proyecto).-

Estas unidades representan los bloques temáticos y fases de la investigación, desde el problema inicial hasta las acciones futuras:

- El reto hotelero (Introducción): Presenta el desafío central del sector hotelero, marcado por las cancelaciones y la variabilidad de la demanda, y el objetivo de optimizar la rentabilidad mediante la anticipación de patrones.
- Modelando ventas: Se enfoca en la aplicación de la Regresión Lineal para evaluar el poder predictivo de variables aisladas (precio y noches de estancia) sobre las ventas.
- Clasificando hoteles: Descripción: Aborda el uso de la Regresión Logística para clasificar el tipo de hotel. Se identifica que la ubicación geográfica es un factor determinante, logrando una alta precisión en la clasificación.
- Comparando propiedades: Utiliza el Análisis de Varianza (ANOVA) para comparar el rendimiento de ventas. El resultado indica que no existen diferencias significativas en el rendimiento promedio de ventas entre las distintas propiedades.
- Hallazgos clave y Próximos Pasos: Consolida las conclusiones principales, como el poder predictivo limitado de las variables simples (precio y noches explican menos del 20% de la variabilidad).
- Acciones Futuras: Proponer desarrollar un Modelo de Revenue Integral (ej. Gradient Boosting) que incorpore más variables (como canal de distribución, estacionalidad, descuentos) y explorar factores ocultos para maximizar la rentabilidad y la ocupación.

4. Los ejes representan las técnicas fundamentales utilizadas para lograr los objetivos del estudio.

5. PROBLEMÁTICA | NECESIDAD | CASO:

Problemáticas Centrales:

Las problemáticas fundamentales que el estudio busca mitigar se centran en la incertidumbre y la ineficiencia en la planificación:

- **Cancelaciones de Última Hora:** La principal problemática es la alta tasa de cancelaciones y su impacto directo en la **ocupación** y los **ingresos** hoteleros. Estas cancelaciones erosionan la rentabilidad y dificultan la gestión del *stock* de habitaciones.
- **Variabilidad de la Demanda:** La dificultad para predecir con precisión los patrones de demanda (**demanda variable**) impide una fijación de precios y una planificación operativa óptima.
- **Predictibilidad Limitada:** Los modelos de regresión simples (utilizando solo precio y noches de estancia) demostraron un **bajo poder predictivo** (explican menos del 20% de la variabilidad de las ventas), indicando que los factores clave que impulsan las ventas aún están "ocultos" o no se han incorporado adecuadamente.

2. Necesidades Operativas y Estratégicas

Para superar las problemáticas, el análisis identifica varias necesidades críticas que la ciencia de datos debe satisfacer:

- **Anticipación de Patrones de Ventas:** Necesidad de herramientas robustas que permitan **predecir las ventas y los ingresos** con mayor precisión que los métodos tradicionales.
- **Optimización de la Rentabilidad (*Revenue Management*):** Requerimiento de un **Modelo de Revenue Integral** que incorpora un conjunto rico de variables (ej. descuentos, canal, antelación) para optimizar los precios y maximizar la ocupación en tiempo real.
- **Segmentación Confiable:** Necesidad de un modelo que permita **clasificar de forma automática y confiable** el tipo de hotel (o segmento de mercado) para aplicar estrategias diferenciadas.
- **Validación de Modelos:** Necesidad de **validar los modelos predictivos** (especialmente el de clasificación) con datos externos (*out-of-time*) y técnicas de *validación cruzada* para asegurar que no hay sobreajuste y que son generalizables.
- **Descubrimiento de Factores Ocultos:** Necesidad de un análisis exploratorio más profundo para **identificar variables no consideradas** (ej. servicios adicionales, motivo del viaje) que explican la mayor parte de la variabilidad de las ventas.

6. FUNDAMENTACIÓN | HIPÓTESIS:

1. Fundamento Empresarial: *Gestión de Ingresos*

- El estudio se enmarca en la disciplina de **Revenue Management** (Gestión de Ingresos), cuyo objetivo es vender el producto correcto al cliente correcto en el momento correcto y por el precio correcto.
- La **problemática central de las cancelaciones** y la **demanda variable** justifican la necesidad de modelos predictivos avanzados que superen la intuición o los métodos históricos, permitiendo fijar precios dinámicos y gestionar el *stock* de habitaciones de forma eficiente.

2. Fundamento Metodológico: Aplicación de Estadísticos Clásicos

- El análisis utiliza tres técnicas estadísticas fundamentales (Regresión Lineal, Regresión Logística y ANOVA), proporcionando una base rigurosa para la toma de decisiones:
 - La **Regresión Lineal** permite cuantificar la relación y el poder predictivo de variables continuas sobre el resultado (ventas).
 - La **Regresión Logística** es indispensable para la **clasificación** y **segmentación** de elementos categóricos (tipo de hotel), clave para estrategias de marketing diferenciadas.
 - El **Análisis de Varianza (ANOVA)** proporciona una herramienta formal para **comparar las medias** de rendimiento (ventas) entre diferentes grupos (propiedades hoteleras), determinando si las diferencias observadas son estadísticamente significativas o producto del azar.

Hipótesis a Prueba:

El estudio pone a prueba explícita e implícitamente varias hipótesis sobre el comportamiento de las variables de reserva:

A. Hipótesis sobre la predicción de Ventas (Regresión Lineal)

- **Hipótesis Nula (\$H_0\$):** El precio y la duración de la estancia no tienen un impacto estadísticamente significativo sobre el monto total de las ventas. (Se supone que no hay relación).

- **Hipótesis Alternativa:** El **precio (*price*)** y la **duración de la estancia (*nights*)** son variables con un poder predictivo individual y significativo sobre el monto de las ventas.
- **Resultado del Estudio:** El estudio **rechaza parcialmente la H_A** , demostrando que si bien existe una comprensión, el poder predictivo de estas dos variables por sí solas es **débil (explican menos del 20%)**, lo que impulsa la necesidad de modelos más complejos.

B. Hipótesis sobre la Clasificación de Hoteles (Regresión Logística)

- **Hipótesis Nula (H_0):** Las variables de reserva y geográficas no son capaces de clasificar de forma confiable el tipo de establecimiento hotelero (*City* o *Resort*).
- **Hipótesis Alternativa (H_A):** Las variables de reserva, especialmente la **ubicación geográfica**, permiten una **clasificación altamente precisa** del tipo de hotel.
- **Resultado del Estudio:** El estudio **acepta la H_A** , logrando una **clasificación casi perfecta**, confirmando que la ubicación y otras características asociadas son excelentes factores discriminatorios.

C. Hipótesis sobre la Comparación de Rendimiento (ANOVA)

- **Hipótesis Nula (H_0):** No existen diferencias estadísticamente significativas en los medios de ventas entre las distintas propiedades hoteleras.
- **Hipótesis Alternativa (H_A):** Los medios de ventas difieren significativamente entre al menos dos de las propiedades hoteleras.
- **Resultado del Estudio:** El estudio **acepta la H_0** , al no encontrar diferencias significativas en el rendimiento promedio de ventas entre las distintas propiedades analizadas.

7. OBJETIVO GENERAL

Optimizar la rentabilidad y la gestión operativa hotelera mediante el análisis predictivo de las reservas, anticipando patrones de ventas, comprendiendo los factores clave que definen los segmentos de negocio y mitigando el impacto de las cancelaciones y la demanda variable.

8. OBJETIVOS ESPECÍFICOS

Los objetivos específicos se centran en el uso de modelos estadísticos para responder a preguntas concretas del negocio:

1. Modelar el Impacto de Variables Clave en las Ventas:

- **Acción:** Aplicar **Regresión Lineal** para determinar si el **precio (price)** y la **duración de la estancia (nights)** tienen un poder predictivo significativo y aislado sobre el monto de las **ventas (sales)**.

2. Clasificar y segmentar las Propiedades Hoteleras:

- **Acción:** Utilizar **Regresión Logística** para construir un modelo de clasificación que permita **discriminar** entre los tipos de establecimientos (*City Hotel* o *Resort Hotel*) de manera automática, identificando las variables que mejor definen cada segmento (ej. ubicación).

3. Comparar el Rendimiento de Ventas entre Propiedades:

- **Acción:** Emplear el **Análisis de Varianza (ANOVA)** para determinar si existen **diferencias estadísticamente significativas en los medios de ventas** entre las distintas propiedades hoteleras.

4. Establecer la Base para un Modelo de Ingreso Integral (Próximos Pasos):

- **Acción:** Con base en el bajo rendimiento de los modelos simples, justificar la necesidad de desarrollar un **Modelo Predictivo Avanzado** (ej. *Gradient Boosting* o Regresión Múltiple) que incorpore un conjunto más rico de variables (canal de distribución, descuentos, antelación, estacionalidad) para la *gestión precisa de ingresos* (Revenue Management).

9. **CRONOGRAMA:** delimitado por la duración del proyecto estudiantil y relacionado con las actividades propias del mismo.

OBJETIVO ESPECÍFICO	ACCIONES, RECURSOS Y TIEMPOS
I. Validación y Robustecimiento de Modelos Actuales	Acciones: Validar el Modelo de Clasificación: Confirmar la generalización del modelo logístico clasificatorio mediante técnicas de <i>validación cruzada</i> y pruebas con un conjunto de datos fuera de <i>tiempo</i> (<i>out-of- time dataset</i>). Recursos: Acceso al conjunto de <i>datos</i> de reservas más recientes (datos de 2018 en adelante) para la validación externa. Tiempo: 1 a 2 semanas.
II. Desarrollo de un Modelo de Ingreso Integral	Acciones: Construir un Modelo Avanzado de Ingresos: Desarrollar un modelo de regresión múltiple o basado en árboles de decisión (Gradiente Boosting) para predecir las ventas con mayor precisión. Recursos: Equipo de Data Science/ML Engineer con experiencia en modelos avanzados. Plataforma de <i>Machine Learning</i> (ej. Python con librerías como Scikit-learn, XGBoost). Tiempo: 4 a 6 semanas
III. Incorporación de Nuevas Variables	Acciones: Enriquecer el <i>Dataset</i> : Incorporar un conjunto más rico de variables al modelo, incluyendo: N° de adultos , Descuentos (<i>disc_amt</i>) , Canal de distribución , Antelación de la reserva (<i>lead-time</i>) y Variables de estacionalidad (mes, trimestre).

	Recursos: Acceso a fuentes de datos operativos internos para estas variables. Tiempo: Integrado en la Fase II
IV. Análisis Exploratorio Avanzado	Acciones: Explorar Factores Ocultos: Realizar un análisis exploratorio de datos (EDA) más profundo para identificar variables no consideradas que explican el restante 80% de la variabilidad en las ventas. Recursos: Analista de datos dedicado. Focus en datos de servicios adicionales (spa, minibar), motivo del viaje (negocios/placer) y la calificación del cliente. Tiempo: 3 a 4 semanas
V. Implementación Operacional	Acciones: Convertir <i>Insights</i> en Acción: Integrar los modelos predictivos finales en Dashboards operativos y herramientas que permitan decisiones automatizadas y en tiempo real (ej. ajuste dinámico de precios). Recursos: Equipo de TI/Desarrollo para integración API y creación de infraestructura de <i>implementación</i> (MLOps). Plataforma de <i>Inteligencia de Negocios</i> (BI). Tiempo: 8 a 12 semanas (Post-modelo final)

10. PRODUCTO FINAL | CONCLUSIONES | RESULTADOS ESPERADOS

El producto final no es solo un informe, sino un conjunto de herramientas de decisión basadas en la ciencia de datos:

1. Modelos Predictivos Validados:

- **Modelo de Clasificación (Regresión Logística):** Un modelo robusto que permite la **segmentación automática y fiable** del tipo de hotel (*City* o *Resort*) basándose en la ubicación y otras características, con una alta precisión.
- **Modelo de *Revenue Management* (Gradient Boosting):** El producto final más crítico, un modelo avanzado que utiliza múltiples variables (precio, descuentos, canal, antelación, estacionalidad) para **predecir el monto de las ventas** con alta precisión, superando las limitaciones de los modelos simples.

2. Panel operativo:

- Una interfaz de *Business Intelligence* que visualiza las **predicciones del modelo avanzado en tiempo real** . Este *panel* permite a los gestores de ingresos (*Revenue Managers*) **tomar decisiones dinámicas** sobre precios, *overbooking* controlado y estrategias de promoción.

3. Informe de Hallazgos y Próximos Pasos:

- Documentación completa que detalla la **metodología, las conclusiones y la justificación** para el desarrollo de un modelo integral, sirviendo como guía estratégica para la inversión futura en *analítica* .

Conclusiones del Estudio Inicial:

Las conclusiones se derivan directamente de las pruebas de las hipótesis iniciales con las técnicas estadísticas:

- **Poder Predictivo Limitado:** Las variables sencillas como el **precio y la duración de la estancia (noches)** son **predictores insuficientes** para modelar las ventas por sí solas (explican menos del 20% de la variabilidad). Esto valida la necesidad de pasar a modelos de *Machine Learning* avanzados y multidimensionales.
- **Segmentación Geográfica Fuerte:** La **ubicación (geográfica)** es un factor determinante y altamente confiable para la **clasificación** del tipo de establecimiento hotelero.
- **Rendimiento Consistente:** No se encontraron **diferencias significativas en el promedio de ventas** entre las distintas propiedades hoteleras analizadas, lo que sugiere que las variaciones observadas son resultado del azar y no de una diferencia estructural en el rendimiento.

Resultados esperados:

La implementación de los modelos avanzados y las acciones propuestas deben conducir a los siguientes resultados:

1. **Aumento de la Rentabilidad (Revenue):** El principal resultado esperado es la **maximización de la ocupación y los ingresos totales** a través de la optimización dinámica de precios, gracias a una predicción de la demanda más precisa.
2. **Reducción del Impacto de Cancelaciones:** Al predecir mejor las ventas, el hotel podrá implementar estrategias de *overbooking* y gestión de *lead-time* más efectivas, **minimizando la pérdida de ingresos** por habitaciones vacías debido a cancelaciones de última hora.
3. **Mejora de la Planificación Estratégica:** Los modelos y *paneles de control* proporcionarán una **visión clara y fundamentada en datos** sobre el rendimiento futuro y la efectividad de las promociones, permitiendo una planificación operativa más eficiente.

4. **Descubrimiento de *Insights* Ocultos:** El análisis exploratorio futuro permitirá **identificar y cuantificar el impacto de los "factores ocultos"** (ej. servicios adicionales, motivo del viaje), que se espera expliquen la mayor parte de la variabilidad restante en las ventas.

11. BIBLIOGRAFÍA: ...

Instituto Politécnico Superior Córdoba - Obtenido de www.lspc.edu.ar

